

V2 Sammanfatta linjär regression (allmän linjär regression)

Gradient descent, maximum likelihood

Regularisering

Korsvalidering

Allmän linjär regression


$$y = f(x)$$

$$G(x, y) = (y, f(x))$$

Vi söker linjära approximation givet ett stickprov (träningdata)



(local regression, kap 7)



$$Y = \beta_0 + \beta_1 X_1 + \epsilon$$

Y	X
y_1	x_1
y_2	x_2
\vdots	\vdots

Y	X_0	X_1
y_1	1	x_{11}
y_2	1	x_{21}
\vdots	\vdots	\vdots

β_0, β_1 skall bestämmas

$$\min C(\beta) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Hur funkar det?


$$(\text{optimering}) \approx \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Derivata \rightarrow sätt till 0 \rightarrow analys

ϵ^2 står kvar i högerledet, dvs vi optimerar mot låg
varians.

$$E[Y|X] = \downarrow \cancel{X\beta}$$

3D:



$$\text{"Lutning på plan"} = \text{gradient} \\ \left(\frac{\partial}{\partial x_1}, \frac{\partial}{\partial x_2} \right) = \Delta f(x_1, x_2)$$



gradienten pekar alltid i den riktning där förändringshastigheten är störst.

$$Y = XB + \epsilon$$

Feature-expansion för att lämna strikta linjära förhållanden

$$Y = \beta_0 + \beta_1 \underline{x_1} + \beta_2 x_2 + \beta_3 x_1 x_2$$

$$Y = \beta_1 x_1 x_2$$



$$O(d^2 n)$$

$$E[Y|X] = f(X)$$

Polynom - expansion:

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1^2 + \beta_4 x_2^2 + \beta_5 x_1 x_2$$

Generell Additiv Modell

(bap 7 i boken)

$$Y = f_0(x_0) + f_1(x_1) + \dots + f_d(x_d) \quad (\epsilon \in)$$

$$\Rightarrow \sum_{i=1}^n x_0 f_0(x_0) \Rightarrow \underline{x_0 f(x)}$$

$$\sim \underline{\text{Pr}(Y|X)}$$



$$E[X] = \mu$$

länk funktion för linjär reg. : μ

$MSE = \text{Bias}^2 + \text{varians} + \text{brus (irreducibel)}$

reguljärisering minskar varians, men tenderar att öka bias.

underfit: (för enkel modell)

låg varians, högt bias
(hög precision, låg noggrannhet)

overfit: (för komplicerad)

hög varians, lågt bias
(låg precision, hög noggrannhet)

Reguljärisering

$$\min C(\beta) = \text{RSS} + \lambda \sum_{i=1}^d \beta_i^2 \quad l_2\text{-norm}$$

- Ridge Regression

$$\min C(\beta) = \text{RSS} + \lambda \sum_{i=1}^d |\beta_i| \quad l_1\text{-norm}$$

- Lasso regression

$$\min C(\beta) = \text{RSS} + \lambda \left(\frac{1-\alpha}{2} \sum_{i=1}^d \beta_i^2 + \alpha \sum_{i=1}^d |\beta_i| \right)$$

- Elasticnet regression