


# SVM Support vector machines

- Grundidé : hyperplan för att separera klasser




$$O(n^3) \sim O(n^2)$$

↑  
design matrixens storlek

- skulle kunna göra feature expansion
- kerneltrick

• Hyperplan har vi redan sett men inte namngivits:

$$\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p = 0$$




(Sparf s. 75) ( $p=3$ )

$$ax + by + cz + d = 0$$

$$\pi = (a, b, c) \quad \text{om } p > 3 \quad \pi = (\beta_1, \dots, \beta_p)$$

$\beta_0 = 0$  så ingår origo, annars inte.

Abstand Punkt/Plan



$$P_0 = (x_0, y_0, z_0)$$

$$A = (p, q, r)$$

$$|\vec{QP}| = \frac{|(x_0 - p)a + (y_0 - q)b + (z_0 - r)c|}{\sqrt{a^2 + b^2 + c^2}}$$


$\Leftrightarrow$

$$|\vec{QP}| = \left| \frac{u \cdot n}{n \cdot n} n \right| \quad \text{Vollkorr: } |n| = 1 = \sqrt{\beta_1^2 + \dots + \beta_p^2}$$

$$n \cdot n = |n|^2$$

$$\sum_{i=1}^p \beta_i^2 = 1$$

$$\left| \frac{u \cdot n}{|n|^2} \right| |n| \Rightarrow \underline{\underline{u \cdot n}}$$



## Maximal margin

Om marginalen måste vara tom  
blir metoden konstlig för brus.

→ Soft Margin

$$\max_{\beta_0, \dots, \beta_p} M$$

sådan att  $\sum_{j=1}^p \beta_j^2 = 1$

( $i \rightarrow$  varje rad i indatan)


$$\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} \geq M(1 - \epsilon_i)$$

$$\epsilon_i \geq 0, \quad \sum_{i=1}^n \epsilon_i \leq C \quad (\text{budget})$$

• Kernel

- Matris med "vikter"

$$u_j \cdot v_i = \sum_{j=1}^n u_j v_j$$



$$\langle u, v \rangle = u \cdot v \text{ (euklidisk)}$$

Klassificeringen kan skrivas som funktion (svår härledning):

$$f(\underline{x}) = \beta_0 + \sum_{i=1}^n \alpha_i \langle \underline{x}, \underline{x}_i \rangle$$

$$\Rightarrow \beta_0 + \sum_{i \in S} \tilde{\alpha}_i \langle \underline{x}, \underline{x}_i \rangle$$

$S$  = support set  
stödvektorerna vi valt

## Kernel funktioner

$$K(u, v) = \left(1 + \sum_{j=1}^p u_j v_j\right)^d \quad \Leftrightarrow (1 + u \cdot v)^d$$

beräknar inre produkter för  $d$ -dimensionella polynom.

$\binom{p+d}{d}$  bas, motsvarar polynom expansion

RBF (Radial basis funktion)

$$K(u, v) = e^{-\gamma \sum_{i=1}^p (u_i - v_i)^2}$$

$\gamma \gg 0$ , liten  $\sigma^2$

$\gamma < 1$ , stor  $\sigma^2$

(mjuka linjer)

$\gamma \Rightarrow$  hyperparameter

## Multimediella klasser

Ova : one-versus-all

ovo : one-versus-one

Kan bli dyrt för stora datamängden (dvs gigabyte+)

## Gradient descent

Grundide: ta ett "litet" steg i en  
"bra" riktning för att nå  
minimum

## Iterativa funktioner

Iteration

$$x_{n+1} = x_n$$

Bastall


$$x_0 = a$$

Logistisk ekvation (iterativ)

$$x_{n+1} = r(1 - x_n)$$


$$x_0 = 0.5$$

$$r = 3.58$$



• Differens ekvation:



itererar över tid



• Differential ekvation

"iteration" (integration) över kontinuerlig tid





$$\left( \frac{\partial \text{RSS}}{\partial b_0}, \frac{\partial \text{RSS}}{\partial b_1} \right)$$

$$= -\nabla$$

- pekar alltid i den  
riktning som har störst  
förändringshastighet

Jacobi  
matris

$$\begin{bmatrix} \frac{\partial x}{\partial a} & \frac{\partial y}{\partial a} \\ \vdots & \vdots \end{bmatrix}$$

OLS:

$$C(\beta) = \text{MSE}$$

Ridge

$$C(\beta) = \text{MSE} + \lambda \sum_{i=1}^p \beta_i^2$$

GD

$$C(\theta) = \frac{1}{n-k-1} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$= \frac{1}{n-k-1} \sum_{i=1}^n (y_i - \theta \cdot x_i)^2$$

some iterative (rekurrent) funktion:

som iterativ funktion:

$$\theta_{i+1} = \theta_i - \eta \nabla J(\theta)$$


$$\theta_{i+1} = \theta_i - \eta \left( \frac{2}{n-k-1} X^T (X \theta_i - y) \right)$$

Batch  $\leftrightarrow$  stickprov (stat. sample)

Sample  $\leftrightarrow$  datapunkt (data point)

Batch Gradient Descent

tenderar att farsta i lokalt min.




# Stochastic Gradient Descent

Välj en slumpmässig datapunkt.

Räkna  $\nabla$  på den punkten.

Upprepa givet antal gånger.

→ gör en "Epoch" (Epoch)



$\eta$  = hur stora  
steg tar vi

konvergerar ej!

## Minibatch

Välj delmängd av punkter och räkna gradient annars som SGD.

## Gradient Descent with Momentum

$$x_{k+1} = x_k - \beta z_k$$

$$x_{k+1} = x_k - \eta \cdot \nabla f_k$$

$$z_k = \nabla f_k + \beta z_{k-1}$$

$$x_{k+1} \dots x_k \dots x_{k-1}$$

